


R para Análisis de Datos

Guía Profesional Completa

Edición 2026



Informe Técnico Especializado

Departamento de Estadística y Ciencia de Datos

Marzo 2026

Contents

1	Introducción	2
1.1	Importancia de R en 2026	2
1.2	Ventajas Competitivas	2
2	Instalación y Configuración	2
2.1	Instalación de R y RStudio	3
2.2	Gestión de Paquetes	3
2.3	Entornos de Desarrollo	3
3	Estructuras de Datos	4
3.1	Vectores	4
3.2	Matrices	5
3.3	Data Frames	5
3.4	Factores	6
4	Tidyverse - Ecosistema Moderno	6
4.1	Paquetes Principales	6
4.2	Pipe Operator (%>%)	7
5	dplyr - Manipulación de Datos	7
5.1	Funciones Principales	7
5.2	Ejemplos Prácticos	8
5.3	GroupBy y Agregación	9
6	ggplot2 - Visualización	9
6.1	Gramática de Gráficos	9
6.2	Tipos de Gráficos	10
6.3	Personalización Avanzada	11
6.4	Faceting	11
7	Estadística con R	11
7.1	Estadística Descriptiva	12
7.2	Pruebas de Hipótesis	12
7.3	Regresión Lineal	12
8	Machine Learning con R	13
8.1	caret - Interfaz Unificada	13
8.2	randomForest	14
8.3	xgboost	14
9	Mejores Prácticas	15
9.1	Estructura de Proyecto Recomendada	16
10	Conclusiones	16

A Recursos de Aprendizaje	16
A.1 Cursos Recomendados	17
A.2 Datasets para Practicar	17
B Referencias Bibliográficas	17

1 Introducción

Definición

R es un lenguaje de programación y entorno software especializado en análisis estadístico, visualización de datos y computación gráfica. Desarrollado por Ross Ihaka y Robert Gentleman en 1995, se ha convertido en el estándar para análisis estadístico académico y profesional.

1.1 Importancia de R en 2026

Información Clave

Estadísticas Clave del Ecosistema R:

- **18,000+** paquetes disponibles en CRAN
- **4 millones+** de usuarios de R en el mundo
- **#1** en análisis estadístico y visualización
- **164 millones+** descargas de ggplot2
- Salario promedio: **\$50k-90k USD/año** para Data Scientists con R

1.2 Ventajas Competitivas

Table 1: Ventajas de R para Análisis de Datos

Ventaja	Descripción
Estadística nativa	Diseñado específicamente para análisis estadístico desde su creación
Visualización superior	ggplot2 produce gráficos publication-ready con mínima configuración
18,000+ paquetes	CRAN ofrece paquetes para cualquier tipo de análisis imaginable
Comunidad académica	Ampliamente usado en investigación científica y publicaciones
Gratuito	Open source sin costos de licencia, mantenido por R Core Team
Reproducibilidad	R Markdown facilita creación de reportes reproducibles

2 Instalación y Configuración

2.1 Instalación de R y RStudio

Ejemplo de Código R

Pasos de Instalación:

```

1 # Paso 1: Descargar e instalar R
2 # Windows/macOS/Linux: https://cran.r-project.org/
3
4 # Paso 2: Descargar e instalar RStudio
5 # https://posit.co/download/rstudio-desktop/
6
7 # Verificar instalación en R
8 R.version

```

2.2 Gestión de Paquetes

Ejemplo de Código R

Instalación y Carga de Paquetes:

```

1 # Instalar paquete individual
2 install.packages("ggplot2")
3
4 # Instalar múltiples paquetes
5 install.packages(c("dplyr", "tidyr", "readr"))
6
7 # Instalar tidyverse completo
8 install.packages("tidyverse")
9
10 # Cargar librerías
11 library(ggplot2)
12 library(dplyr)
13 library(tidyverse)

```

2.3 Entornos de Desarrollo

Table 2: Entornos de Desarrollo para R

Herramienta	Tipo	Uso Recomendado
RStudio	IDE completo	Desarrollo profesional, proyectos
VS Code + R	Editor extensible	Desarrollo multi-lenguaje
Jupyter + IRkernel	Notebook web	Exploración, enseñanza
RStudio Cloud	Cloud gratuito	Colaboración, sin instalación

3 Estructuras de Datos

Definición

R ofrece cinco estructuras de datos fundamentales: **vectores**, **matrices**, **data frames**, **listas** y **factores**. Cada una tiene propósitos específicos en el análisis de datos.

3.1 Vectores

Ejemplo de Código R

Creación y Manipulación de Vectores:

```
1  # Crear vectores
2  vector_numerico <- c(1, 2, 3, 4, 5)
3  vector_caracter <- c("a", "b", "c")
4  vector_logico <- c(TRUE, FALSE, TRUE)
5
6  # Secuencias
7  secuencia <- 1:10
8  secuencia2 <- seq(0, 100, by = 10)
9
10 # Operaciones
11 vector_numerico + 10      # [11, 12, 13, 14, 15]
12 vector_numerico * 2      # [2, 4, 6, 8, 10]
13
14 # Funciones estadísticas
15 mean(vector_numerico)    # 3 - promedio
16 sd(vector_numerico)     # 1.58 - desviación estándar
17
18 # Indexing
19 vector_numerico[1]       # Primer elemento
20 vector_numerico[1:3]     # Primeros 3 elementos
21 vector_numerico[vector_numerico > 3] # Elementos > 3
```

3.2 Matrices

Ejemplo de Código R

Operaciones con Matrices:

```

1  # Crear matriz
2  matriz <- matrix(1:9, nrow = 3, ncol = 3)
3
4  # Operaciones
5  t(matriz)          # Transpuesta
6  diag(matriz)       # Diagonal
7  det(matriz)        # Determinante
8
9  # Multiplicación matricial
10 A <- matrix(1:4, nrow = 2)
11 B <- matrix(5:8, nrow = 2)
12 A %*% B            # Producto matricial

```

3.3 Data Frames

Ejemplo de Código R

Data Frames - Estructura Principal:

```

1  # Crear data frame
2  df <- data.frame(
3    Nombre = c("Ana", "Luis", "Carlos"),
4    Edad = c(25, 30, 35),
5    Salario = c(50000, 60000, 55000)
6  )
7
8  # Exploración
9  str(df)          # Estructura
10 summary(df)      # Resumen estadístico
11 head(df)         # Primeras filas
12 dim(df)          # Dimensiones
13
14 # Acceder a columnas
15 df$Nombre        # Usando $
16 df[["Nombre"]]   # Usando [[]]
17 df[, 1]          # Por posición
18
19 # Agregar columna
20 df$Ciudad <- c("Madrid", "Barcelona", "Sevilla")

```

3.4 Factores

Table 3: Estructuras de Datos en R

Estructura	Dimensión	Tipo de Datos
Vector	1D	Homogéneo
Matriz	2D	Homogéneo
Data Frame	2D	Heterogéneo
Lista	N/A	Cualquier tipo
Factor	1D	Categorico

4 Tidyverse - Ecosistema Moderno

Definición

Tidyverse es una colección de paquetes R diseñados para ciencia de datos con sintaxis consistente y filosofía compartida. Representa el enfoque moderno para análisis de datos en R.

4.1 Paquetes Principales

Table 4: Paquetes Principales del Tidyverse

Paquete	Propósito	Funciones Clave
ggplot2	Visualización	<code>ggplot()</code> , <code>geom_*()</code>
dplyr	Manipulación	<code>filter()</code> , <code>select()</code> , <code>mutate()</code>
tidyr	Limpieza	<code>pivot_longer()</code> , <code>pivot_wider()</code>
readr	Importación	<code>read_csv()</code> , <code>read_tsv()</code>
purrr	Programación funcional	<code>map()</code> , <code>reduce()</code>
tibble	Data frames modernos	<code>tibble()</code> , <code>as_tibble()</code>
stringr	Cadenas de texto	<code>str_detect()</code> , <code>str_replace()</code>
forcats	Manejo de factores	<code>fct_reorder()</code> , <code>fct_relevel()</code>

4.2 Pipe Operator (%>%)

Ejemplo de Código R

Encadenamiento de Operaciones:

```

1 # Sin pipe (anidamiento dif cil de leer)
2 head(select(filter(mtcars, mpg > 20), mpg, hp), 5)
3
4 # Con pipe (legible y claro)
5 mtcars %>%
6   filter(mpg > 20) %>%
7   select(mpg, hp) %>%
8   head(5)
9
10 # Pipe nativo de R (>= 4.1)
11 mtcars |>
12   filter(mpg > 20) |>
13   select(mpg, hp) |>
14   head(5)

```

5 dplyr - Manipulación de Datos

5.1 Funciones Principales

Table 5: Funciones Principales de dplyr

Función	Propósito	Ejemplo
<code>select()</code>	Seleccionar columnas	<code>select(df, col1, col2)</code>
<code>filter()</code>	Filtrar filas	<code>filter(df, condicion)</code>
<code>mutate()</code>	Crear columnas	<code>mutate(df, nueva = expr)</code>
<code>arrange()</code>	Ordenar datos	<code>arrange(df, col)</code>
<code>summarise()</code>	Agregar datos	<code>summarise(df, avg = mean(col))</code>
<code>group_by()</code>	Agrupar operaciones	<code>df %>% group_by(col)</code>

5.2 Ejemplos Prácticos

Ejemplo de Código R

Pipeline Completo de Manipulación:

```
1 library(dplyr)
2 data(mtcars)
3
4 # Ejemplo integrado
5 resultado <- mtcars %>%
6   filter(mpg > 15) %>%
7   select(mpg, hp, wt, cyl) %>%
8   mutate(
9     eficiencia = mpg / wt,
10    categoria = case_when(
11      cyl == 4 ~ "Económico",
12      cyl == 6 ~ "Medio",
13      cyl == 8 ~ "Potente"
14    )
15  ) %>%
16  group_by(categoria) %>%
17  summarise(
18    count = n(),
19    avg_mpg = mean(mpg),
20    avg_hp = mean(hp),
21    .groups = "drop"
22  ) %>%
23  arrange(desc(avg_mpg))
24
25 print(resultado)
```

5.3 GroupBy y Agregación

Ejemplo de Código R

Agrupamiento y Resumen:

```

1 # Agrupar y resumir
2 mtcars %>%
3   group_by(cyl) %>%
4   summarise(
5     count = n(),
6     avg_mpg = mean(mpg),
7     sd_mpg = sd(mpg)
8   )
9
10 # Múltiples agrupamientos
11 mtcars %>%
12   group_by(cyl, am) %>%
13   summarise(
14     count = n(),
15     avg_hp = mean(hp)
16   )

```

6 ggplot2 - Visualización

Definición

ggplot2 es un sistema de visualización basado en la "Gramática de Gráficos". Permite construir gráficos capa por capa de manera declarativa y consistente.

6.1 Gramática de Gráficos

Table 6: Componentes de ggplot2

Componente	Función	Ejemplo
ggplot()	Inicializa gráfico	ggplot(data = mtcars)
aes()	Mapea variables	aes(x = wt, y = mpg)
geom_*()	Tipo de gráfico	geom_point()
scale_*()	Controla escalas	scale_color_manual()
facet_*()	Crea paneles	facet_wrap(~cyl)
theme_*()	Personaliza apariencia	theme_minimal()

6.2 Tipos de Gráficos

Ejemplo de Código R

Gráficos Comunes:

```
1 library(ggplot2)
2
3 # 1. Scatter Plot
4 ggplot(mtcars, aes(x = wt, y = mpg)) +
5   geom_point() +
6   labs(title = "Peso vs MPG")
7
8 # 2. Histograma
9 ggplot(mtcars, aes(x = mpg)) +
10   geom_histogram(binwidth = 2,
11                  fill = "steelblue",
12                  color = "white")
13
14 # 3. Boxplot
15 ggplot(mtcars, aes(x = factor(cyl),
16                    y = mpg,
17                    fill = factor(cyl))) +
18   geom_boxplot() +
19   theme_minimal()
20
21 # 4. Gráfico de Líneas
22 ggplot(economics, aes(x = date, y = unemploy)) +
23   geom_line() +
24   labs(title = "Desempleo en el Tiempo")
```

6.3 Personalización Avanzada

Ejemplo de Código R

Gráfico Completamente Personalizado:

```

1 ggplot(mtcars, aes(x = wt, y = mpg,
2                   color = factor(cyl))) +
3   geom_point(size = 3, alpha = 0.7) +
4   geom_smooth(method = "lm", se = FALSE) +
5   labs(
6     title = "Relación Peso-Eficiencia",
7     subtitle = "Datos de 32 automviles de 1974",
8     x = "Peso (lbs)",
9     y = "Millas por Galón",
10    color = "Cilindros"
11  ) +
12  scale_color_brewer(palette = "Set1") +
13  theme_minimal() +
14  theme(
15    plot.title = element_text(
16      hjust = 0.5, size = 14, face = "bold"
17    ),
18    panel.grid.minor = element_blank()
19  )

```

6.4 Faceting

Ejemplo de Código R

Crear Múltiples Paneles:

```

1 # Facet wrap
2 ggplot(mtcars, aes(x = wt, y = mpg)) +
3   geom_point() +
4   facet_wrap(~cyl)
5
6 # Facet grid
7 ggplot(mtcars, aes(x = wt, y = mpg)) +
8   geom_point() +
9   facet_grid(am ~ cyl)

```

7 Estadística con R

7.1 Estadística Descriptiva

Ejemplo de Código R

Resumen Estadístico Completo:

```

1 # Resumen completo
2 summary(mtcars$mpg)
3
4 # Estadísticas específicas
5 mean(mtcars$mpg)      # Promedio
6 median(mtcars$mpg)    # Mediana
7 sd(mtcars$mpg)        # Desviación estándar
8 var(mtcars$mpg)       # Varianza
9 quantile(mtcars$mpg, probs = c(0.25, 0.5, 0.75))
10 IQR(mtcars$mpg)      # Rango intercuartílico

```

7.2 Pruebas de Hipótesis

Table 7: Pruebas Estadísticas Comunes

Prueba	Función R	Uso
Prueba t (1 muestra)	t.test(x, mu = valor)	Comparar media con valor
Prueba t (2 muestras)	t.test(y ~ grupo)	Comparar dos grupos
ANOVA	aov(y ~ grupo)	Comparar múltiples grupos
Chi-cuadrado	chisq.test(tabla)	Independencia de variables
Correlación	cor(x, y)	Relación entre variables

7.3 Regresión Lineal

Ejemplo de Código R

Modelo de Regresión:

```

1 # Regresión simple
2 modelo <- lm(mpg ~ wt, data = mtcars)
3 summary(modelo)
4
5 # Regresión múltiple
6 modelo_multi <- lm(mpg ~ wt + hp + cyl, data = mtcars)
7 summary(modelo_multi)
8
9 # Diagnósticos
10 par(mfrow = c(2, 2))
11 plot(modelo)

```

8 Machine Learning con R

8.1 caret - Interfaz Unificada

Definición

caret (Classification And REgression Training) proporciona una interfaz unificada para entrenar y evaluar más de 200 modelos de machine learning.

Ejemplo de Código R

Pipeline de Machine Learning:

```
1 library(caret)
2 data(iris)
3
4 # Dividir datos
5 set.seed(123)
6 train_index <- createDataPartition(iris$Species,
7                                     p = 0.8, list = FALSE)
8 train_data <- iris[train_index, ]
9 test_data <- iris[-train_index, ]
10
11 # Cross-validation
12 control <- trainControl(method = "cv", number = 10)
13
14 # Entrenar modelo
15 modelo <- train(
16   Species ~ .,
17   data = train_data,
18   method = "rf",
19   trControl = control
20 )
21
22 # Predicciones y evaluaci n
23 predicciones <- predict(modelo, test_data)
24 confusionMatrix(predicciones, test_data$Species)
```

8.2 randomForest

Table 8: Algoritmos de Machine Learning en R

Algoritmo	Paquete	Uso
Random Forest	randomForest	Clasificación y regresión
Gradient Boosting	xgboost	Alta precisión
Regresión Logística	caret	Clasificación binaria
SVM	e1071	Clasificación no-lineal
K-Means	stats	Clustering

8.3 xgboost

Ejemplo de Código R

Gradient Boosting con XGBoost:

```

1 library(xgboost)
2
3 # Preparar datos
4 dtrain <- xgb.DMatrix(
5   data = as.matrix(train_data[, 1:4]),
6   label = as.numeric(train_data$Species) - 1
7 )
8
9 # Entrenar modelo
10 modelo_xgb <- xgboost(
11   data = dtrain,
12   nrounds = 100,
13   objective = "multi:softprob",
14   num_class = 3,
15   eval_metric = "mlogloss"
16 )
17
18 # Predicciones
19 predict(modelo_xgb, as.matrix(test_data[, 1:4]))

```


9 Mejores Prácticas

Mejor Práctica

Organización de Código:

- Usar nombres descriptivos: `promedio_mpg` en lugar de `x`
- Comentar código complejo explicando el **por qué**, no el qué
- Usar pipes para legibilidad en operaciones encadenadas
- Cargar paquetes al inicio del script

Mejor Práctica

Manejo de Datos:

- Validar datos con `stopifnot()` antes del análisis
- Usar tipos apropiados: `factor()` para categóricas
- Manejar valores nulos explícitamente
- Mantener datos originales sin modificar (`raw/` vs `processed/`)

Mejor Práctica

Visualización:

- Usar paletas accesibles: `scale_color_viridis_d()`
- Etiquetar claramente con `labs()`
- Mantener gráficos limpios con `theme_minimal()`
- Guardar en alta resolución: `ggsave("file.png", dpi = 300)`

9.1 Estructura de Proyecto Recomendada

Ejemplo de Código R

Organización de Directorios:

```

1 proyecto/
2     data/
3         raw/           # Datos originales (no modificar)
4     )
5         processed/     # Datos procesados
6         external/      # Datos externos
7     scripts/
8         01_carga.R
9         02_limpieza.R
10        03_analisis.R
11    reports/           # R Markdown
12    output/            # Gráficos, tablas
13    .Rproj             # Proyecto RStudio
    README.md

```

10 Conclusiones

R se mantiene como la herramienta líder para análisis estadístico y visualización de datos en 2026. Su ecosistema maduro, comunidad activa y enfoque en reproducibilidad lo hacen indispensable para científicos de datos.

Información Clave

Puntos Clave para Recordar:

- **Tidyverse** es el estándar moderno para análisis de datos en R
- **ggplot2** produce los mejores gráficos publication-ready
- **caret** unifica 200+ algoritmos de ML en una interfaz
- **R Markdown** facilita reportes reproducibles
- La **comunidad académica** de R es excepcionalmente activa

Recomendación Final: Comience con fundamentos (estructuras de datos, tidyverse), progrese a visualización (ggplot2), y luego avance a estadística y machine learning. La práctica con proyectos reales y la participación en la comunidad son esenciales.

A Recursos de Aprendizaje

A.1 Cursos Recomendados

Table 9: Plataformas de Aprendizaje de R

Plataforma	Curso	Costo
Coursera	Data Science Specialization (Johns Hopkins)	Subscription
edX	Data Science MicroMasters (UC San Diego)	\$
DataCamp	Data Scientist with R	Subscription
R for Data Science	Libro online gratuito	Gratis
Swirl	Aprende R en R	Gratis

A.2 Datasets para Practicar

- **datasets** (incorporado) – mtcars, iris, diamonds
- **gapminder** – Datos mundiales de desarrollo
- **nycflights13** – Vuelos desde NYC
- **tidytuesday** – Datos semanales para práctica
- **mlbench** – Datasets para machine learning

B Referencias Bibliográficas

- Wickham, H. et al. (2023). *R for Data Science (2nd ed.)*. O'Reilly Media.
- Grolemund, G. & Wickham, H. (2014). *Hands-On Programming with R*. O'Reilly Media.
- Kuhn, M. & Johnson, K. (2019). *Feature Engineering and Selection*. CRC Press.
- CRAN. (2026). *Comprehensive R Archive Network*. <https://cran.r-project.org/>
- RStudio. (2026). *Posit PBC*. <https://posit.co/>